

Derin Pekiştirmeli Öğrenme Tabanlı Yaya ve Acil Araç Öncelikli Akıllı Kavşak Kontrol Sistemi

Şevval Uzar , Bursa Teknik Üniversitesi, Email: *bmsevvaluzar@gmail.com

Abstract—Bu çalışmada, trafik yoğunluğunun zaman içinde değiştiği dört kollu bir kavşakta araç, yaya ve acil araç hareketlerini eş zamanlı olarak yönetebilen derin pekiştirmeli öğrenme tabanlı bir trafik ışığı kontrol sistemi geliştirilmiştir. Çalışmada gerçek bir veri seti yerine, şerit bazlı araç gelişleri, yaya yoğunluğu, yoğun saat senaryoları, geçici şerit kapanmaları ve ambulans/itfaiye olaylarını içeren özel bir simülasyon ortamı oluşturulmuştur. Önerilen modelde Double Deep Q-Network algoritması kullanılmış; ajan, araç kuyrukları, araç ve yaya bekleme süreleri, aktif trafik fazı, kapalı şerit bilgisi, acil araç konumu ve trafik yoğunluğu gibi durum bilgilerini gözlemleyerek karar vermiştir. Aksiyon uzayı, farklı araç ve yaya geçiş fazları ile 8, 12 ve 16 saniyelik dinamik yeşil ışık sürelerinden oluşturulmuştur. Ödül fonksiyonu; araç ve yaya kuyruklarını, bekleme sürelerini ve acil araç gecikmesini azaltırken kavşaktan geçen araç ve yaya sayısını artırmayı hedeflemiştir. Ayrıca, yaya veya acil araçların belirlenen maksimum bekleme süresini aşması durumunda devreye giren güvenlik tabanlı öncelik mekanizması eklenmiştir. Eğitim sonuçları, modelin değişken trafik koşullarına uyum sağlayarak trafik fazlarını dinamik biçimde seçebildiğini göstermektedir. Geliştirilen sistem, akıllı ulaşım uygulamalarında yaya güvenliği ve acil araç geçiş önceliğini destekleyen adaptif trafik kontrolüne yönelik bir yaklaşım sunmaktadır.

Anahtar Kelimeler—Double Deep Q-Network, dinamik yeşil ışık süresi, yaya bekleme süresi, acil araç önceliklendirme, şerit kapanması, Markov karar süreci.

I. GİRİŞ

Trafik ışığı kontrolü, araç yoğunluğu, yaya güvenliği ve acil araç geçişi gibi farklı ihtiyaçların aynı anda yönetilmesini gerektiren önemli bir akıllı ulaşım problemidir. Sabit zamanlı trafik ışıkları, önceden belirlenen sürelerle çalıştığından yoğun saatler, ani araç birikimleri, yaya talepleri ve şerit kapanmaları karşısında yeterince uyum sağlayamayabilir. Bu durum araç ve yaya bekleme sürelerinin artmasına, kuyrukların uzamasına ve ambulans veya itfaiye gibi acil araçların gecikmesine neden olmaktadır.

Bu çalışmada, dört kollu bir kavşakta trafik ışıklarını dinamik olarak kontrol eden Derin Pekiştirmeli Öğrenme tabanlı bir sistem önerilmiştir. Simülasyon ortamında toplam 12 araç şeridi, dört yaya geçidi, yoğun saat trafik değişimi, geçici şerit kapanması ve acil araç senaryosu bulunmaktadır. Model; araç ve yaya kuyrukları, bekleme süreleri, aktif trafik fazı, kapalı şerit bilgisi ve acil aracın bulunduğu yön gibi durumları değerlendirerek karar vermektedir.

Önerilen yöntemde Double Deep Q-Network algoritması kullanılmıştır. Ajan, beş trafik fazı ile 8, 12 ve 16 saniyelik üç farklı yeşil ışık süresi arasından seçim yapmaktadır. Böylece toplam 15 farklı aksiyon üzerinden trafik ışığı fazı ve yeşil

süre birlikte belirlenmektedir. Ayrıca, acil araç veya yaya bekleme süresi belirlenen sınırı geçtiğinde devreye giren güvenlik tabanlı öncelik mekanizması kullanılmıştır.

Bu çalışmanın temel araştırma sorusu, Double DQN tabanlı sistemin değişken trafik koşulları altında araç ve yaya kuyruklarını azaltıp azaltamayacağıdır. Buna ek olarak, acil araç önceliği ve şerit kapanması senaryolarında sistemin adaptif karar üretme başarısı incelenmektedir.

Çalışmanın katkısı; araç, yaya, acil araç ve şerit kapanması durumlarını tek bir trafik sinyal kontrol ortamında birleştirmesidir. Modelin performansı eğitim ödülü, araç-yaya kuyruk uzunluğu, geçiş sayısı ve acil araç bekleme süresi üzerinden değerlendirilecektir.

II. DOUBLE DEEP Q-NETWORK YÖNTEMİ

Trafik ışığı kontrol problemi bir Markov Karar Süreci olarak modellenmiştir. Bu yapı

$$M = (S, A, P, R, \gamma) \quad (1)$$

şeklinde ifade edilmektedir. Burada S durum uzayını, A aksiyon uzayını, P durum geçişlerini, R ödül fonksiyonunu ve γ indirim katsayısını göstermektedir.

TABLO I
AKSİYON UZAYI

Faz	Açıklama
0	Kuzey-Güney düz ve sağ dönüş
1	Doğu-Batı düz ve sağ dönüş
2	Kuzey-Güney sol dönüş
3	Doğu-Batı sol dönüş
4	Yaya geçiş fazı

Aksiyon uzayı beş trafik fazı ve üç farklı yeşil ışık süresinden oluşmaktadır. Buna göre ajan toplam 15 farklı aksiyon seçebilmektedir.

Her faz için 8, 12 ve 16 saniyelik yeşil ışık süreleri kullanılmaktadır. Faz değişimlerinde üç saniyelik sarı ışık süresi uygulanmaktadır. Acil araç bekleme süresi 10 saniyeyi veya yaya bekleme süresi 34 saniyeyi aşarsa, güvenlik katmanı devreye girerek ilgili fazı zorunlu olarak seçmektedir.

Ödül fonksiyonu; araç ve yaya kuyruklarını, bekleme sürelerini ve acil araç gecikmesini azaltacak şekilde tasarlanmıştır. Buna karşılık kavşaktan geçen araç ve yaya sayısı ödül olarak eklenmiştir.

$$R_t = 0.02[-0.55Q_v - 1.10Q_p - 0.012W_v - 0.045W_p + 0.75V_t + 1.50P_t - E_t - C_t] \quad (2)$$

Burada Q_v araç kuyruklarını, Q_p yaya kuyruklarını, W_v araç bekleme maliyetini, W_p yaya bekleme maliyetini, V_t geçen araç sayısını ve P_t geçen yaya sayısını göstermektedir. E_t acil araç gecikme cezasını, C_t ise kapalı şeritteki ek kuyruk maliyetini ifade etmektedir. Faz değişiminde ayrıca gereksiz geçişleri azaltmak için ek ceza uygulanmaktadır.

Çalışmada Double DQN kullanılmıştır. Double DQN’de sonraki aksiyon çevrimiçi ağ ile seçilirken, bu aksiyonun Q-değeri hedef ağ üzerinden hesaplanmaktadır.

$$y_t = r_t + (1 - d_t) \gamma^{\Delta t} Q_{\theta^-} \left(s_{t+1}, \arg \max_a Q_{\theta}(s_{t+1}, a) \right) \quad (3)$$

Model, tahmin edilen Q-değeri ile hedef Q-değeri arasındaki farkı Smooth L1 Loss fonksiyonu kullanarak azaltmaktadır.

$$L(\theta) = \text{Huber}(Q_{\theta}(s_t, a_t), y_t) \quad (4)$$

Model Python programlama dili kullanılarak geliştirilmiştir. Uygulamada PyTorch, NumPy, Matplotlib, ImageIO ve Pillow kütüphanelerinden yararlanılmıştır. Hiperparametreler kodda varsayılan deney ayarları olarak belirlenmiştir; Grid Search veya Random Search uygulanmamıştır.

TABLO II
DOUBLE DQN EĞİTİM SÜRECİ

Adım	İşlem
1	Ortamı ve Replay Buffer yapısını başlat.
2	Her eğitim bölümü için başlangıç durumunu oluştur.
3	Epsilon-greedy stratejisi ile aksiyon seç.
4	Ortamda aksiyonu uygula ve ödül ile sonraki durumu elde et.
5	Durum, aksiyon, ödül ve sonraki durum geçişini Replay Buffer’a ekle.
6	Buffer yeterli büyüklüğe ulaştığında mini-batch örnekle.
7	Double DQN hedef değerini hesapla.
8	Smooth L1 Loss ile çevrimiçi ağı güncelle.
9	Belirli aralıklarla hedef ağ parametrelerini güncelle.
10	Bölüm tamamlanana kadar işlemleri tekrarla.

TABLO III
DOUBLE DQN HİPERPARAMETRELERİ

Parametre	Değer
Eğitim bölümü	500
Maksimum simülasyon süresi	360 saniye
Öğrenme oranı	0.001
Batch size	128
Replay Buffer kapasitesi	50.000
İndirim katsayısı	0.995
Hedef ağ güncelleme aralığı	400 adım
Eğitim başlangıç eşiği	1.000 geçiş
Başlangıç epsilon değeri	1.00
Minimum epsilon değeri	0.05
Epsilon azalma adımı	9.000
Ağ mimarisi	67-160-160-15
Aktivasyon fonksiyonu	ReLU
Optimizasyon algoritması	Adam
Kayıp fonksiyonu	Smooth L1 Loss

III. DENEYSEL ÇALIŞMALAR VE BULGULAR

A. Eğitim Sürecinin Değerlendirilmesi

Double DQN modeli 500 bölüm boyunca eğitilmiştir. Eğitim sırasında her bölümde elde edilen toplam ödül kaydedilmiş ve sonucun daha okunabilir olması için 20 bölümlük hareketli ortalama hesaplanmıştır. Şekil 1’de görüldüğü gibi, ilk bölümlerde ödül değerleri oldukça değişkendir. Bunun nedeni ajanın yüksek epsilon değeri nedeniyle farklı aksiyonları keşfetmesidir. Eğitim ilerledikçe hareketli ortalama yükselmiş ve model daha dengeli kararlar üretmeye başlamıştır.

İlk bölümlerde hareketli ortalama yaklaşık -1400 seviyesindeyken, eğitim sonunda -600 ile -700 aralığına yaklaşmıştır. Bu değişim, aracın ve yayanın bekleme süresi ile kuyruk maliyetlerini azaltmaya yönelik daha uygun trafik fazları seçildiğini göstermektedir. Bazı bölümlerde görülen ani düşüşler; yoğun saat trafiği, şerit kapanması




Fig. 1. Double DQN modelinin bölüm bazlı eğitim ödülü ve 20 bölümlük hareketli ortalaması.

TABLO IV
EĞİTİM SÜRECİNİN GENEL DEĞERLENDİRMESİ

Ölçüt	Gözlem
Eğitim bölümü	500
Başlangıç hareketli ortalama ödülü	Yaklaşık -1400
En yüksek hareketli ortalama ödülü	Yaklaşık -500
Son eğitim bölümlerindeki ortalama ödül	Yaklaşık -600/ -700
Epsilon başlangıç değeri	1.00
Epsilon son değeri	0.05
Eğitim davranışı	İlk bölümlerde yüksek dalgalanma, sonraki bölümlerde daha kararlı öğrenme

veya acil araç senaryoları gibi rastgele çevresel koşullardan kaynaklanmaktadır. Model 500 bölüm boyunca eğitilmiş, epsilon değeri zamanla 0.05 seviyesine düşürülmüştür.

Tablo IV ve Şekil 1 birlikte değerlendirildiğinde, modelin rastgele keşif aşamasından öğrenilmiş politika aşamasına geçtiği görülmektedir. Ödül değerleri sıfıra ulaşmamıştır; çünkü simülasyonda araç ve yaya bekleme maliyetleri sürekli olarak ödül fonksiyonuna ceza olarak yansıtılmaktadır. Bu nedenle amaç ödülü pozitif yapmak değil, toplam maliyeti mümkün olduğunca azaltmaktır.

B. Kavşak Simülasyonunun Görsel Değerlendirilmesi

Şekil 2’te programatik olarak oluşturulan kavşak görüntüsü verilmiştir. Simülasyonda dört kollu kavşak, toplam 12 araç şeridi, dört yaya geçidi ve trafik ışıkları modellenmiştir. Araçlar düz, sağ ve sol dönüş şeritlerinde ayrı kuyruklar hâlinde gösterilmektedir. Yaya geçitlerinde bekleyen kişi sayısı ve ortalama bekleme süresi de görüntülenmektedir.




Fig. 2. Derin pekiştirmeli öğrenme tabanlı trafik ışığı kontrol sisteminin kavşak simülasyonu görünümü.

Acil araç oluştuğunda ambulans, kırmızı-beyaz araç simgesiyle gösterilmektedir. Şerit kapanması senaryosunda ise ilgili şerit üzerinde “X” işareti bulunmaktadır. Bu görsel, modelin yalnızca araç yoğunluğunu değil; yaya yoğunluğu, acil araç durumu ve kapalı şerit bilgisini de değerlendirdiğini göstermektedir. Simülasyon çıktısı GIF formatında ayrıca sunulmuştur.

C. Performans Metrikleri

Model değerlendirilirken aşağıdaki metriklerin kullanılması önerilmektedir:

- Ortalama araç kuyruk uzunluğu
- Ortalama yaya kuyruk uzunluğu
- Toplam geçen araç sayısı
- Toplam geçen yaya sayısı
- Acil araç bekleme süresi
- Faz değişim sayısı
- Son araç ve yaya kuyruk uzunluğu

Mevcut kod, toplam geçen araç/yaya sayısı, acil araç geçiş durumu, faz değişim sayısı ve son kuyruk bilgilerini değerlendirme sonunda üretmektedir.

IV. SONUÇLAR VE TARTIŞMA

Bu çalışmada, dört kollu bir kavşakta araç, yaya, acil araç ve şerit kapanması durumlarını birlikte

TABLO V
DEĞERLENDİRME METRİKLERİ

Metrik	Açıklama
Toplam geçen araç	Kavşaktan başarıyla geçen araç sayısı
Toplam geçen yaya	Yaya fazında geçiş yapan kişi sayısı
Acil araç geçişi	Ambulans/itfaiyenin öncelikli faz ile geçip geçmediği
Acil araç bekleme süresi	Acil aracın kavşakta beklediği süre
Faz değişim sayısı	Eğitim sonrası modelin yaptığı trafik ışığı faz değişimi
Son araç kuyruğu	Simülasyon sonunda bekleyen araç sayısı
Son yaya kuyruğu	Simülasyon sonunda bekleyen yaya sayısı

değerlendiren Double DQN tabanlı adaptif trafik ışığı kontrol sistemi geliştirilmiştir. Model; şerit bazlı araç kuyrukları, yaya yoğunluğu, bekleme süreleri, aktif faz, acil araç bilgisi ve trafik yoğunluğu gibi durumları kullanarak trafik fazı ile yeşil ışık süresini dinamik olarak belirlemiştir. Eğitim sürecinde toplam ödül değerinin başlangıç bölümlerine göre yükselmesi, modelin zamanla daha uygun kontrol kararları öğrenebildiğini göstermektedir.

Elde edilen bulgular, özellikle değişken trafik yoğunluğu altında sabit süreli kontrol yerine adaptif karar mekanizmasının daha uygun olduğunu göstermektedir. Double DQN yaklaşımı, araç ve yaya kuyruklarını aynı anda dikkate alırken ambulans veya itfaiye gibi acil araçlar için öncelikli geçiş sağlayabilmektedir. Ayrıca, maksimum yaya ve acil araç bekleme süreleri için tanımlanan güvenlik kuralları, modelin yalnızca trafik akışına değil; güvenlik ve adil hizmet gereksinimlerine de odaklanmasını sağlamaktadır.

Literatürdeki çalışmalar incelendiğinde, birçok DRL tabanlı trafik sinyal kontrol yönteminin araç gecikmesini ve kuyruk uzunluğunu azaltmaya odaklandığı görülmektedir [1]–[4]. Yaya davranışını veya adalet kriterlerini dikkate alan çalışmalar da bulunmaktadır [5]–[7]. Acil araç geçişini ele alan çalışmalar ise genellikle çok ajanlı veya geniş yol ağı temelli yapılar kullanmaktadır [8]. Bu çalışmanın farkı; araç, yaya, acil araç önceliği, yoğun saat trafiği ve geçici şerit kapanması gibi farklı durumları tek kavşak düzeyinde aynı model içerisinde birleştirmesidir. Bu yönüyle çalışma, daha yönetilebilir bir simülasyon ortamında çok amaçlı trafik sinyal kontrolü sunmaktadır.

Çalışmanın güçlü yönleri; şerit bazlı araç mod-

ellemesi, yaya bekleme süresinin doğrudan duruma ve ödül fonksiyonuna eklenmesi, acil araç öncelik mekanizması ve dinamik yeşil ışık süresi seçimidir. Buna karşılık bazı sınırlılıklar bulunmaktadır. İlk olarak, deneyler gerçek trafik verisi yerine özel olarak oluşturulan simülasyon ortamında gerçekleştirilmiştir. İkinci olarak, model yalnızca tek bir kavşağı ele almakta ve komşu kavşaklarla koordinasyonu kapsamamaktadır. Ayrıca hiperparametreler varsayılan deney ayarlarıyla belirlenmiş; Grid Search veya Random Search gibi sistematik optimizasyon yöntemleri uygulanmamıştır.

Gelecek çalışmalarda modelin SUMO gibi daha gerçekçi trafik simülasyon ortamlarıyla bütünleştirilmesi, gerçek kamera veya sensör verileriyle test edilmesi ve birden fazla kavşağı kapsayan çok ajanlı pekiştirmeli öğrenme yapısına dönüştürülmesi planlanmaktadır. Bunun yanında PPO, Dueling DQN ve Actor-Critic gibi farklı derin pekiştirmeli öğrenme algoritmalarının karşılaştırılması, hiperparametre optimizasyonu yapılması ve toplu taşıma araçları için öncelik mekanizması eklenmesi önerilmektedir.

REFERENCES

- [1] V. Mnih et al., “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.
- [2] H. van Hasselt, A. Guez, and D. Silver, “Deep reinforcement learning with double Q-learning,” in *Proc. AAAI*, 2016, pp. 2094–2100.
- [3] A. Haydari and Y. Yilmaz, “Deep reinforcement learning for intelligent transportation systems: A survey,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, no. 1, pp. 11–32, 2022.
- [4] W. Genders and S. Razavi, “Using a deep reinforcement learning agent for traffic signal control,” arXiv preprint arXiv:1611.01142, 2016.
- [5] H. Wei et al., “IntelliLight: A reinforcement learning approach for intelligent traffic light control,” in *Proc. ACM SIGKDD*, 2018, pp. 2496–2505.
- [6] L. Li, Y. Lv, and F.-Y. Wang, “Traffic signal timing via deep reinforcement learning,” *IEEE/CAA Journal of Automatica Sinica*, vol. 3, no. 3, pp. 247–254, 2016.
- [7] T. Chu, J. Wang, L. Codecà, and Z. Li, “Multi-agent deep reinforcement learning for large-scale traffic signal control,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 21, no. 3, pp. 1086–1095, 2020.
- [8] M. A. Khamis and W. Gomaa, “Adaptive multi-objective reinforcement learning with hybrid exploration for traffic signal control based on cooperative multi-agent framework,” *Engineering Applications of Artificial Intelligence*, vol. 29, pp. 134–151, 2014.